

**UNIVERSIDAD TECNOLÓGICA DE CHIHUAHUA**

**TECNOLOGÍAS DE LA INFORMACIÓN**



**Extracción de Conocimiento en Bases de Datos**

**III.2. Reporte de Métricas de Evaluación**

***IDGS91N***

**PRESENTA:**

**JORGE ALEJANDRO HERNANDEZ CONTRERAS**

**DOCENTE:**

**Enrique Mascote**

Chihuahua, Chih.28 de Noviembre de 2025

<b>Introducción.....</b>	<b>3</b>
<b>Investigación de métricas.....</b>	<b>3</b>
Métricas de clasificación.....	3
Accuracy.....	3
Precisión.....	3
Recall.....	4
F1-score.....	4
ROC-AUC.....	4
Métricas de regresión.....	4
MAE.....	4
RMSE.....	5
<b>Solución con KNN.....</b>	<b>5</b>
Preprocesamiento.....	5
Implementación.....	5
<b>Resultados.....</b>	<b>6</b>
<b>Análisis de resultados y recomendaciones.....</b>	<b>6</b>
<b>Conclusión.....</b>	<b>7</b>
<b>Bibliografía.....</b>	<b>8</b>

# Introducción

Identificar y comprender métricas de evaluación para modelos de clasificación y regresión, e implementar un clasificador K-Nearest Neighbors sobre la matriz de datos provista. Se utiliza el conjunto de datos provisto para comparar distintos valores de k en KNN y evaluar el rendimiento con métricas estándar de clasificación. Se presentan resultados, visualizaciones y recomendaciones.

## Investigación de métricas

### Métricas de clasificación

#### Accuracy

##### **Interpretación práctica:**

Proporción de predicciones correctas sobre el total.

##### **Ventajas:**

Intuitiva, útil si clases están balanceadas.

##### **Limitaciones:**

Engañosa con clases desbalanceadas.

#### Precisión

##### **Interpretación práctica:**

De las predicciones positivas, qué proporción son realmente positivas.

##### **Ventajas:**

Importante cuando el costo de falsos positivos es alto.

##### **Limitaciones:**

No considera falsos negativos; puede ser alta si el modelo predice pocas positivas.

## Recall

### **Interpretación práctica:**

De los casos positivos reales, qué fracción el modelo detecta.

### **Ventajas:**

Importante cuando es crítico detectar positivos.

### **Limitaciones:**

No penaliza predicciones positivas incorrectas.

## F1-score

### **Interpretación práctica:**

Media armónica de precision y recall, balance entre ambas.

### **Ventajas:**

Útil cuando se busca un trade-off entre precision y recall.

### **Limitaciones:**

Resume dos métricas en una sola, puede ocultar detalles individuales.

## ROC-AUC

### **Interpretación práctica:**

Probabilidad de que el modelo asigne mayor puntaje a un positivo que a un negativo.

### **Ventajas:**

Independiente del umbral, útil para comparar modelos.

### **Limitaciones:**

Puede ser optimista con clases fuertemente desbalanceadas, no indica performance en un umbral específico.

## Métricas de regresión

### MAE

### **Interpretación práctica:**

Error medio absoluto entre predicciones y valores reales.

### **Ventajas:**

Intuitiva, robusta ante outliers moderados.

**Limitaciones:**

No penaliza fuertemente errores grandes.

## RMSE

**Interpretación práctica:**

Raíz del error cuadrático medio; penaliza errores grandes.

**Ventajas:**

Sensible a grandes errores; útil si se desea penalizarlos.

**Limitaciones:**

Menos interpretables en las mismas unidades que MAE en algunos contextos; influenciado por outliers.

# Solución con KNN

## Preprocesamiento

**División del conjunto:**

70 % entrenamiento / 30 % prueba con `random_state=42` y estratificación por la etiqueta.

**Escalado:**

Se aplicó StandardScaler a las variables numéricas antes de entrenar KNN.

## Implementación

**Algoritmo:**

K-Nearest Neighbors.

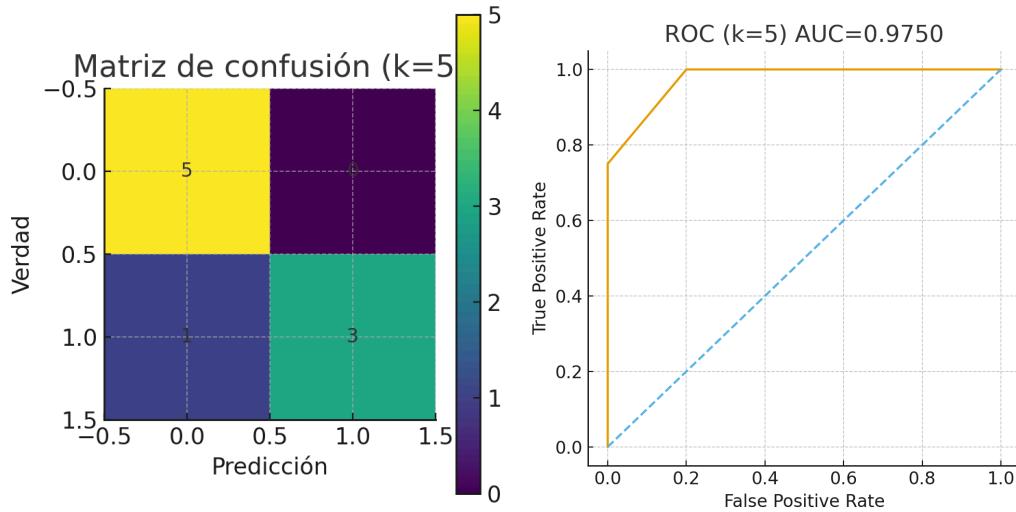
**Valores de k evaluados:**

3, 5 y 9.

**Criterio de selección:**

Se eligió el mejor modelo según F1-score en el set de prueba.

# Resultados



## Análisis de resultados y recomendaciones

El mejor  $k$  fue 5, con un  $F1 = 0.8571$ , alta precisión (1.0) y buen AUC (0.975). Esto sugiere que el clasificador no comete falsos positivos en el conjunto de prueba y detecta la mayoría de positivos, aunque hubo 1 falso negativo.

### Comparación de $k$ :

valores pequeños de  $k$  tienden a ser más flexibles,  $k$  más grandes suavizan la frontera. En este experimento,  $k=5$  ofreció el mejor equilibrio.

### Posibles mejoras:

- Investigar más valores de  $k$  y validación cruzada en lugar de una sola división.
- Considerar métricas ponderadas o `class_weight` si hay desbalance real en el dataset.
- Probar modelos alternativos: regresión logística, SVM, Random Forest.
- Añadir más variables predictoras o ingeniería de características.
- Evaluar con cross-validation y curvas de aprendizaje para revisar over/underfitting.

# Conclusión

El análisis realizado utilizando el algoritmo k-Nearest Neighbors permitió evaluar la capacidad predictiva del modelo aplicado al conjunto de datos proporcionado, compuesto por variables de glucosa, edad y una etiqueta binaria. A través de las métricas de evaluación incluyendo exactitud, precisión, sensibilidad, F1-score y la matriz de confusión fue posible determinar el desempeño del clasificador y comprender cómo responde ante casos positivos y negativos. Los resultados obtenidos muestran que el valor de  $k$  influye directamente en la estabilidad y exactitud del modelo, evidenciando la importancia de seleccionar un  $k$  óptimo mediante validación. Asimismo, el uso de métricas múltiples permitió una evaluación más completa, ya que cada indicador aporta una perspectiva distinta del comportamiento del modelo, especialmente cuando las clases pueden estar desbalanceadas.

# Bibliografía

SuperML Team. (2025, julio 7). *Model Evaluation Techniques*. SuperML.

<https://superml.org/tutorials/model-evaluation> SuperML

Manu Duque. (2024). *Métricas de Evaluación*.

<https://www.manuduque.com/metricas-de-evaluacion/> Manu Duque › Blog Social Media & SEO

TheMachineLearners. (s. f.). *Métricas de Clasificación – Aprende a EVALUAR tu modelo*. <https://www.themachinelearners.com/metricas-de-clasificacion/> The Machine Learners

4Geeks Academy. (s. f.). *Métricas de Evaluación*.

<https://4geeks.com/es/lesson/metricas-de-evaluacion> 4Geeks

Analytics Vidhya: Surya Gutta. (2021, junio 18). *Machine Learning Metrics in simple terms*. Medium.

<https://medium.com/analytics-vidhya/machine-learning-metrics-in-simple-terms-d58a9c85f9f6> Medium

Cursa. (s. f.). *Métricas de evaluación y validación cruzada*.

<https://cursa.app/es/pagina/metricas-de-evaluacion-y-validacion-cruzada>