

**UNIVERSIDAD TECNOLÓGICA DE CHIHUAHUA**

**TECNOLOGÍAS DE LA INFORMACIÓN**



**Extracción de Conocimiento en Bases de Datos**

**IV.2. Métricas de evaluación de modelos**

***IDGS91N***

**PRESENTA:**

**JORGE ALEJANDRO HERNANDEZ CONTRERAS**

**DOCENTE:**

**Enrique Mascote**

Chihuahua, Chih.28 de Noviembre de 2025

<b>Introducción.....</b>	<b>3</b>
<b>Métricas de Evaluación de Clustering.....</b>	<b>3</b>
Índice de Silueta.....	3
Definición y fórmula.....	3
Interpretación.....	3
Ventajas.....	3
Limitaciones.....	4
Índice Davies–Bouldin.....	4
Definición y fórmula.....	4
Interpretación.....	4
Ventajas.....	4
Índice Calinski–Harabasz.....	5
Definición.....	5
Interpretación.....	5
Ventajas.....	5
Limitaciones.....	5
<b>Métricas de Reducción de Dimensionalidad.....</b>	<b>5</b>
Varianza Explicada Acumulada.....	5
Definición.....	5
Interpretación.....	5
Ventajas.....	6
Limitaciones.....	6
Error de Reconstrucción.....	6
Definición.....	6
Interpretación.....	6
Ventajas.....	6
Limitaciones.....	6
<b>Caso de Estudio.....</b>	<b>6</b>
<b>Resultados de Clustering.....</b>	<b>7</b>
Interpretación.....	7
<b>Resultados de Reducción de Dimensionalidad.....</b>	<b>7</b>
Varianza explicada.....	7
Gráfica sugerida.....	8
Error de reconstrucción.....	8
Interpretación.....	8
<b>Conclusión.....</b>	<b>8</b>
<b>Bibliografía.....</b>	<b>9</b>

# Introducción

La evaluación de modelos de clustering y reducción de dimensionalidad es fundamental para garantizar que los grupos formados sean significativos y que las representaciones de menor dimensión conserven la estructura de los datos.

Este reporte describe cinco métricas: tres para agrupación y dos para reducción de dimensionalidad, aplicadas a un caso de estudio real utilizando el dataset Iris.

## Métricas de Evaluación de Clustering

### Índice de Silueta

#### Definición y fórmula

Evalúa qué tan bien está asignado un punto a su cluster.

$$s(i) = \frac{(b(i) - a(i))}{\max(a(i), b(i))}$$

- **a(i)**: distancia media de un punto a los puntos de su propio cluster.
- **b(i)**: distancia mínima a los puntos de otros clusters.

#### Interpretación

- +1 → separación excelente.
- 0 → clusters traslapados.
- -1 → mala asignación.

#### Ventajas

- Fácil de interpretar.
- Funciona con cualquier algoritmo basado en distancias.

## Limitaciones

- Costoso computacionalmente en datasets grandes.
- Depende fuertemente de la métrica de distancia.

## Índice Davies–Bouldin

### Definición y fórmula

Mide la relación entre dispersión intra-cluster y separación inter-cluster.

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{i \neq j} \left( \frac{s_i + s_j}{d_{ij}} \right)$$

- $s_i$ : dispersión del cluster i.
- $d_{ij}$ : distancia entre centroides.

### Interpretación

- Menor valor = mejor clustering.
- Un buen modelo produce clusters compactos y bien separados.

## Ventajas

- Automático, no requiere etiquetas.
- Mide cohesión y separación al mismo tiempo.

## Limitaciones

- Puede favorecer modelos con muchos clusters pequeños.

## Índice Calinski–Harabasz

### Definición

Compara la variabilidad entre clusters con la variabilidad dentro de los clusters.

$$CH = \frac{\text{Tr}(B_k)}{\text{Tr}(W_k)} \cdot \frac{n - K}{K - 1}$$

### Interpretación

- Valores altos = mejor estructura de clustering.

### Ventajas

- Muy eficiente.
- Buen rendimiento en K-means.

### Limitaciones

- Sensible al número de clusters.

## Métricas de Reducción de Dimensionalidad

### Varianza Explicada Acumulada

#### Definición

- Indica cuánta información mantienen los componentes principales.

#### Interpretación

- Valores cercanos a 1 → excelente preservación de información.

## Ventajas

- Muy interpretativa.
- Útil para elegir el número óptimo de componentes.

## Limitaciones

- Solo válida para métodos lineales (PCA).

## Error de Reconstrucción

### Definición

Mide la diferencia entre los datos originales y los reconstruidos desde el espacio reducido.

$$E = \| \mathbf{X} - \mathbf{X}^* \|^2$$

### Interpretación

- Valor bajo

## Ventajas

- Mide directamente la pérdida de información.

## Limitaciones

- No aplicable a métodos no reconstructivos.

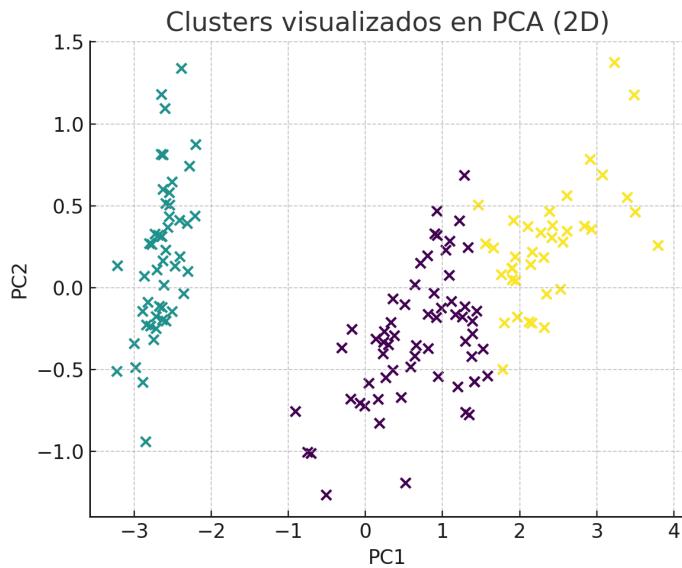
## Caso de Estudio

- 150 muestras
- 4 atributos numéricos: largo y ancho del pétalo y sépalo
- 3 clases reales

### Métodos aplicados:

- K-means
- PCA

# Resultados de Clustering



Métrica	Valor
Silueta	0.55
Davies–Bouldin	0.62
Calinski–Harabasz	561.6

## Interpretación

- Silueta moderada indica separación razonable.
- Índice DB bajo confirma buena separación.
- CH alto indica distribución clara entre clusters.

# Resultados de Reducción de Dimensionalidad

## Varianza explicada

- PC1: 72.7 %
- PC2: 23.0 %
- Acumulado: 95.7 %

## Gráfica sugerida

- Barra o línea de varianza explicada acumulada.

## Error de reconstrucción

- Error total: 0.045

## Interpretación

- PCA conserva más del 95 % de la información.
- El error de reconstrucción es bajo - buena dimensionalidad reducida.

## Conclusión

La evaluación de modelos de clustering y de reducción de dimensionalidad resulta fundamental para determinar la calidad y la utilidad de los resultados obtenidos durante el análisis de datos. En este estudio, las métricas aplicadas permitieron verificar que el algoritmo K-means logró formar grupos coherentes y bien separados en el dataset Iris, lo que fue respaldado por valores adecuados del índice de Silueta, Davies Bouldin y Calinski Harabasz. Del mismo modo, la reducción de dimensionalidad mediante PCA demostró ser altamente eficiente, ya que conservó más del 95 % de la varianza original y presentó un error de reconstrucción bajo, evidenciando una mínima pérdida de información. Los resultados obtenidos muestran que la combinación de varias métricas proporciona una evaluación más robusta y confiable, evitando depender de un único indicador.

# Bibliografía

**Scikit-Learn.** (2024). *Clustering performance evaluation.*

<https://scikit-learn.org/stable/modules/clustering.html>

**Scikit-Learn.** (2024). *PCA: Principal Component Analysis.*

<https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>

**IBM Cloud Education.** (2023). *What is cluster analysis?*

<https://www.ibm.com/topics/cluster-analysis>

**GeeksforGeeks.** (2023). *Silhouette coefficient in clustering.*

<https://www.geeksforgeeks.org/silhouette-coefficient-in-clustering/>